Gonzalez Vazquez Rodrigo

"Arquitectura para bases de datos distribuidas"

¿Qué es una Base de Datos Distribuida?

Se define como una colección de múltiples bases de datos lógicamente interrelacionadas distribuidas a través de una red de computadoras y a través de un **Sistema Gestor de Bases de Datos Distribuidas (SGBDD)** permite administrar esta base de datos haciendo la distribución transparente para los usuarios donde se requiere que los datos estén lógicamente relacionados con una estructura bien definida y teniendo acceso a través de una interfaz común.

Distribución de Datos vs. Centralización

El objetivo fundamental es la integración sin centralización: los datos pueden estar físicamente distribuidos, pero lógicamente integrados.

Base de Datos Centralizada	Base de Datos Distribuida
Datos en una sola ubicación física	Datos en múltiples sitios de la red
Control centralizado del SGBD	Control distribuido con coordinación global
Sin problemas de sincronización entre sitios	Sincronización compleja entre transacciones
Recuperación ante fallos más simple	Tolerancia a fallos mediante réplicas
Rendimiento limitado a un nodo	Paralelismo y mejor rendimiento potencial

Existen razones técnicas y organizacionales que justifican la distribución:

- Mejor correspondencia con la estructura organizacional de empresas distribuidas geográficamente.
- Mayor confiabilidad y disponibilidad del sistema ante fallos.
- Mejora del rendimiento mediante paralelismo y localidad de los datos.
- Aplicaciones inherentemente distribuidas: comercio electrónico, aplicaciones web, multimedia, manufactura.
- Escalabilidad: posibilidad de agregar sitios sin rediseñar todo el sistema.

La distribución introduce complejidades adicionales derivadas principalmente de tres factores:

- **Replicación de datos:** El sistema debe elegir la copia correcta para lecturas y asegurar que las actualizaciones se reflejen en todas las copias.
- **Fallos parciales:** Si algunos sitios o enlaces de comunicación fallan durante una actualización, el sistema debe garantizar que los efectos se apliquen al recuperarse.

- **Falta de información instantánea:** La sincronización de transacciones entre múltiples sitios es considerablemente más difícil que en sistemas centralizados.

La arquitectura de un sistema define su estructura: los componentes, las funciones de cada uno y sus interrelaciones. Özsu y Valduriez desarrollan tres arquitecturas de referencia para los SGBDD, clasificada y la combinación de estas dimensiones genera hasta 18 posibles alternativas arquitectónicas, aunque no todas son significativas en la práctica. El libro se enfoca en tres modelos principales: (A0, D1, H0) para Cliente/Servidor, (A0, D2, H0) para Par-a-Par, y (A2, D2, H1) para el sistema de Multibases de Datos.

Arquitectura Genérica de un SGBD Centralizado

Las capas funcionales de un SGBD centralizado (de arriba hacia abajo) son:

- **Interfaz**: Gestiona la comunicación con las aplicaciones y la gestión de vistas.
- **Control**: aplica restricciones de integridad semántica y verificaciones de autorización.
- **Compilación (Procesamiento de Consultas):** Descompone y optimiza las consultas en un árbol de operaciones algebraicas.
- **Ejecución**: Dirige la ejecución de los planes de acceso e incluye el manejo de transacciones.
- **Acceso a Datos:** Gestiona estructuras de archivos, índices y buffers en memoria.
- **Consistencia**: Controla la concurrencia y el registro de operaciones (logging) para recuperación.

Modelo arquitectónico: Cliente/Servidor

Los sistemas **Cliente/Servidor** entraron en escena a principios de los años 90 y tuvieron un impacto significativo. La idea central es distinguir la funcionalidad del sistema en dos clases: funciones del servidor y funciones del cliente. En los sistemas relacionales, el servidor realiza la mayor parte del trabajo de gestión de datos (procesamiento y optimización de consultas, gestión de transacciones y almacenamiento), mientras que el cliente proporciona la interfaz de usuario y un módulo cliente del SGBD.

Existen **diferentes tipos de arquitectura** Cliente/Servidor:

Variante	Descripción
Múltiple Cliente / Servidor Único	Un solo servidor almacena toda la BD y gestiona todas las solicitudes. Desde la perspectiva de gestión de datos es similar a una BD centralizada, aunque con diferencias en la ejecución de transacciones y gestión de caché.
Múltiple Cliente / Múltiple Servidor	Varios servidores en el sistema. Cada cliente gestiona su propia conexión con el servidor apropiado ('cliente pesado') o cada cliente conoce solo a su 'servidor hogar' que se comunica con otros servidores ('cliente ligero').
Arquitectura de Tres Niveles (3-Tier)	Extensión natural: servidores de interfaz (web), servidores de aplicación y servidores de base de datos. Cada tipo de servidor se especializa en su función.
Servidor de Base de Datos (Database Machine)	Concentra todas las funciones de gestión de datos en un servidor dedicado, aprovechando paralelismo y optimizaciones específicas para bases de datos.

En la arquitectura Cliente/Servidor de referencia, el servidor aloja:

- Controlador semántico de datos
- Optimizador de consultas
- Gestor de transacciones
- Gestor de recuperación
- Procesador de soporte en tiempo de ejecución

El cliente aloja el módulo **SGBD cliente**, responsable de gestionar los datos en caché y, en algunos casos, los bloqueos de transacciones en caché, donde la transparencia de acceso a datos se provee en la interfaz del servidor.

Modelo Arquitectónico Par-a-Par (Peer-to-Peer)

En los sistemas Par-a-Par no existe diferenciación entre clientes y servidores: cada sitio tiene funcionalidad completa de SGBD y puede comunicarse con otros para ejecutar consultas y transacciones. Este modelo fue el enfoque predominante en los trabajos iniciales sobre bases de datos distribuidas.

Los sistemas **Par-a-Par modernos** presentan **dos diferencias importantes respecto** a sus **predecesores**: la escala masiva (miles de sitios vs. decenas) y la **heterogeneidad** e independencia inherentes de cada sitio.

Organización de Datos — Esquemas

La arquitectura de referencia Par-a-Par define cuatro niveles de esquemas:

Esquema	Función
Esquema Interno Local (LIS)	Describe la organización física de los datos en cada sitio. Puede ser diferente en cada nodo.
Esquema Conceptual Local (LCS)	Describe la organización lógica de los datos en cada sitio, incluyendo fragmentos y réplicas.
Esquema Conceptual Global (GCS)	Describe la estructura lógica de todos los datos en todos los sitios. Es la unión de los LCS. Provee transparencia de red.
Esquema Externo (ES)	Define las vistas de los usuarios y las aplicaciones sobre el GCS. Pueden existir múltiples ES.

Procesador de Usuario

- Manejador de interfaz de usuario: interpreta comandos de usuario y formatea los resultados.
- Controlador semántico de Datos: verifica restricciones de integridad y autorizaciones definidas en el GCS.
- Optimizador global de consultas y descomponedor: determina la estrategia de ejecución óptima, traduciendo consultas globales en locales usando los esquemas global y local.
- Monitor de ejecución distribuida (Gestor de transacciones distribuidas): coordina la ejecución distribuida de solicitudes entre múltiples sitios.

Modelo Arquitectónico de Multibases de Datos

Los Sistemas de Multibases de Datos (MDBS) representan el caso donde los SGBD individuales son completamente autónomos y no tienen concepto de cooperación: pueden no saber de la existencia de otros ni cómo comunicarse con ellos. En la literatura actual se usa frecuentemente el término sistema de integración de datos, aunque los autores mantienen la distinción porque los MDBS se enfocan estrictamente en fuentes de bases de datos.

Los autores definen tres dimensiones de autonomía que caracterizan a los MDBS:

Autonomía de diseño: Cada SGBD puede utilizar los modelos de datos y técnicas de gestión de transacciones que prefiera.

Autonomía de comunicación: Cada SGBD decide qué información proporcionar a los demás sistemas o al software de control global.

Autonomía de ejecución: Cada SGBD puede ejecutar las transacciones que se le sometan de la manera que considere conveniente.

Arquitectura Mediador/Wrapper

La implementación popular para MDBS es la arquitectura Mediador/Wrapper, propuesta por Wiederhold (1992). Sus elementos principales son:

Componente	Función
Mediador	Módulo de software que explota el conocimiento codificado sobre conjuntos de datos para crear información para capas superiores. Implementa el GCS y gestiona consultas sobre él. Los mediadores pueden construirse sobre otros mediadores, creando implementaciones en capas.
Wrapper	Proporciona el mapeo entre la vista del SGBD fuente y la vista de los mediadores. Maneja la heterogeneidad de los sistemas fuente (p.ej., mapear un sistema relacional a una interfaz orientada a objetos usada por los mediadores).

Una colección de mediadores puede verse como una capa de middleware que provee servicios por encima de los sistemas fuente, con interfaces claramente definidas. Esta arquitectura permite la integración gradual de sistemas heterogéneos y es la base de muchos sistemas de integración de datos modernos.

Comparativa de Arquitecturas

Característica	Cliente/Servidor	Par-a-Par	Multibases de Datos
Distribución de roles	Clientes y servidores diferenciados	Todos los sitios iguales	SGBD autónomos + capa MDBS
Autonomía local	Baja — control centralizado en servidor	Baja-Media — cooperación requerida	Alta — cada SGBD es independiente
Heterogeneidad	Generalmente homogéneo	Generalmente homogéneo	Puede ser heterogéneo
Esquema global	Gestionado por servidor/s	GCS = unión de LCS locales	GCS = subconjunto compartido
Diseño del GCS	Top-down	Top-down	Bottom-up (integración)
Escalabilidad	Media	Alta (miles de nodos modernos)	Alta
Casos de uso típicos	Aplicaciones empresariales, ERP	Sistemas distribuidos clásicos	Integración de datos heterogéneos